투비닥터 연구팀 / 중간 회의 / 2026년 11월 8일

합성 면담 발화의 사고 전환 분석

반복을 유도하면 같은 표현은 늘었다. 그러나 반복을 많이 쓴 답변이 곧 생각 사이의 연결이 약한 답변은 아니었다. 또 '더 강한 탈선'을 지시해도 실제 발화에서 불명확한 전환이 일관되게 늘지는 않았다.

분석 자료와 판독 방법

같은 가상 인물에 대해 여섯 질문과 19개 조건을 조합한 팀 발화 228개를 확보했다. Claude 114개는 대화 중 시범 작성 뒤 일부 지시를 조정했고, GPT-4.1 114개는 API로 생성했다. 두 자료를 분리해 같은 질문끼리 비교했다. 각 질문·조건당 발화는 하나다.

전환은 "앞뒤 구절은 각각 이해되지만 둘 사이의 관계가 불분명한 곳이 한 군데 이상 있는가"로 정의했다. 기준 조정에 사용한 가족 질문은 강도 비교에서 제외했다. AI가 조건과 출처를 가리고 판독한 뒤 조건표를 연결했다.

강도를 높였을 때의 결과

자료 · 조건당 5개	다주제 대조	중간 탈선 지시	강한 탈선 지시
Claude	0 / 0 / 5	5 / 0 / 0	5 / 0 / 0
GPT-4.1	0 / 0 / 5	0 / 4 / 1	1 / 3 / 1

각 칸은 '불명확한 전환 있음 / 불확실 / 없음' 순서의 발화 수.

GPT-4.1에서 중간 지시 때 불확실했던 네 질문 중 영화만 '있음'으로 바뀌었다. 주말과 성장 지역은 불확실로 남았고, 요리는 '없음'이 됐다. Claude는 중간 지시부터 모두 '있음'이어서 이 지표로는 추가 강도를 구별할 수 없다.

무엇을 측정하고 무엇을 검증할 것인가

반복 지표의 쓰임과 한계

강한 반복 지시에서 기본 조건보다 3단어 묶음 반복률이 여섯 질문 모두 높아졌다. 질문별 평균 차이는 Claude +26.94%p, GPT-4.1 +8.44%p였다. 두 주 비교의 다중검정 보정 후 p값은 각각 0.0625로, 5% 유의성에는 이르지 않았다.

별도로 인접 구절에서 같은 단어를 되받는 비율도 측정했다. 중간 반복 지시는 다주제 대조보다 두 자료 모두 5/5 질문에서 높았다. 중간 탈선과 중간 반복을 직접 비교하면 탈선 쪽이 높은 질문은 Claude 5/5, GPT-4.1 1/5였다. 되받기는 문체를 기술하는 데 쓰되, 탈선 단독 지표로는 쓰지 않는다.

원문 예시: 같은 답변에서 '야간 택시 일 → 야간 택시 일의 위험'은 단어가 반복돼도 자연스럽다. 반대로 '뱀의 허물(skins) → 인체 피부(skin)의 크기'는 생각의 연결이 약하지만 단수·복수 차이 때문에 동일 단어 규칙이 놓쳤다.

본 실험에 남은 질문

"범주명만 제시할 때보다 구체적 지시를 덧붙일 때 불명확한 전환이 늘어나는가?" 별도 서점 사례의 기존 발화 16개에서는 구체 지시+탈선 4개가 모두 불확실했다. 네 조건을 모두 판정할 수 있는 묶음은 0/4였고, 효과의 가능 범위는 −50~+100%p였다. 효과가 없다는 뜻은 아니다.

회의에서 결정할 사항

① 동일 사례·질문·모델로 고정한 본 실험을 실행할지 결정한다. 개발 사례 대조조건 8개와 미사용 가상 사례 4개의 확인용 96개는 아직 생성하지 않았다.

② 전문의가 AI 판정을 보기 전 독립적으로 읽을 표본과 자문 일정을 정한다. 96개 생성 시 사전 선정한 24개를 검토할 계획이다. 현재 전문의 판독은 0건이며, 이 결과를 임상 타당도나 모델 성능 순위로 해석하지 않는다.